

2026-08-17 更新:reader prompt 修复(比较类问题答案错位)

一、问题发现:翻具体案例,而不是只看聚合指标

在 gate 三信号对照实验(0810 更新)完成之后,对 D 组(特征级融合,MuSiQue dev 全量)做了一次 案例分析,而不是继续在聚合指标上调参。先把"答错的案例"按"检索是否全对"拆开:

	数量
答错(EM=0)	1376
其中:每一跳都选中了 gold 段落,但最终答案依然错	485

这 485 个"检索/gate 全部做对、答案还是错"的案例,跟检索和 gate 完全无关,问题出在最后一步 "综合所有中间结果生成答案"的 reader 身上。把这 485 个案例的最终答案,跟每一跳自己生成的短 答案(prior)逐个比
对,分成三类:

类型	数 量	占比
最终答案 = 最后一跳短答案,但 EM 判定仍为错(纯粹是措辞跟 gold 不完全一致,如 "McKinley" vs "President McKinley")	372	77%
最终答案 = 更早一跳的短答案(reader 真的选错了该用哪一跳的结论)	39	8%
两者都不匹配(reader 自己重新综合出一个新的错误答案)	74	15%

第一类是 EM 指标本身的严格性导致的,不是真实错误。第二、三类才是真问题,合计约 23%。

在 2WikiMultihopQA、HotpotQA 上重复同样的分析,发现"reader 选错跳"这个模式**不是 MuSiQue 特有**
的,而且在另外两个数据集上比例更高:

数据集	检索全对但答错	其中"reader 选错跳"	占比
MuSiQue	485	39	8.0%
2WikiMultihopQA	4894	639	13.1%
HotpotQA	1522	232	15.2%

进一步看 2WikiMultihopQA、HotpotQA 里的具体案例,发现"选错跳"经常集中在**比较类问题**上
(2WikiMultihopQA 数据集里专门有一个 **comparison** 问题类型),而且不是简单的"选了错误的那一 跳",是
reader 根本没有执行"比较"这个动作,直接把某一跳查到的原始事实(通常是日期)当成 答案输出:

```
Q: Which film was released more recently, Royal Treasure or When Love Begins?
gold: Royal Treasure | final: January 15, 2016
每跳短答案(prior): ['January 15, 2016', '2008']
```

```
Q: Did the board game San Marco or About Time come out first?
gold: San Marco | final: 2001
每跳短答案(prior): ['2001', '2007']
```

两跳分别查出了两部电影/两款桌游各自的日期,但最终该输出的是"哪一个"(片名/游戏名), reader 却直接把其中一个日期原样吐出来了。

二、根因与修复:reader prompt 缺一句"比较类问题"的显式指令

最终答案生成用的 prompt 由 `retrieval/run_retrieval_exp_wavefront.py::build_final_reader_cot_prompt` 构造,其中唯一约束答案格式的一句是:

```
Give a short span or phrase only (entity, date, number, or yes/no).
```

这句话把"date"(日期)"number"(数字)明确列为**合法的答案类型**,对所有问题一视同仁。对大多数桥接类问题(bridge)来说,"最后一跳的短答案就是最终答案"这个假设是对的;但对比较类问题来说,每一跳查到的日期/数字只是**用来做比较判断的中间量**,真正该输出的是比较之后胜出 的那个实体名字——prompt 里完全没有区分这两种情况,reader 于是经常直接把某一跳的日期当答案。

修复是在 `run_retrieval_exp_wavefront.py` 里新增一个函数 `build_final_reader_cot_prompt_comparison_hint`(**保留原函数不动**,新函数追加在旁边), 在原 prompt 基础上只加一句话:

```
If the original question asks you to COMPARE two or more entities (for
example "which was
released more recently", "who was born first", "which is longer"), the per-
step answers
above are the values used to make that comparison, not the final answer
themselves -- you
must perform the comparison yourself and answer with the NAME of the entity
that satisfies
it, not a date, number, or other raw value.
```

`retrieval/run_retrieval_exp_wavefront_gate_v3_rawprefix.py` 新增 `--final-reader-prompt {default,comparison_hint}` 参数,可以在两个版本之间切换,其余流程(检索、gate 打分、逐跳候选选择)完全不变——保证这是一次干净的单变量对照。

三、结果:2WikiMultihopQA 全量验证

MuSiQue dev、 $\lambda=0.50$ 、rawprefix,只切 `--final-reader-prompt`:

	recall@1	chain@1	EM	F1
default prompt	0.9289	0.8613	0.4990	0.5759

	recall@1	chain@1	EM	F1
comparison_hint	0.9289	0.8613	0.5982	0.6770
差值	持平	持平	+9.92	+10.11

recall@1、chain@1 完全没变——检索和 gate 全都没动,证明提升干干净净来自这一句 prompt 改动。
EM/F1 涨了约 10 个百分点,是这个项目目前为止单次改动里最大的一次提升,超过 λ 调参、rawprefix 文本对齐、BGE 检索前缀这几项加起来的总和。

同时验证了根因诊断是对的:"reader 选错跳"这个 bug 的复现率从 13.1%(639/4894)降到 **2.6%** (98/3833),降了 5 倍。

四、MuSiQue、HotpotQA 验证——进行中

MuSiQue、HotpotQA 上用同样的 `comparison_hint` prompt 全量验证正在跑,预期 HotpotQA(修复前 "选错跳" 占比 15.2%,三个数据集里最高)提升会更明显。跑完后补充这两个数据集的对比表,并考虑 把 `comparison_hint` 定为 D 组(及 B/C 组)端到端流程的新默认 prompt,回填 `gate_v3_main_method_report.md` 里所有引用"当前完整方法"的数字。