

# 2026-09-21 更新：global setting 下扩大候选池——召回/重排从 top10 扩到 top50

## 一、问题

global setting 下，每一跳的候选不再来自这道题自带的约 20 篇段落，而是从整个数据集 dev split 去重合并的 共享语料库里检索（MuSiQue 21,100 篇 / 2Wiki 56,687 篇 / HotpotQA 66,635 篇）。之前的 global 评测每跳只 召回 BGE 前 10 篇、交给 gate 重排：gold 只要没进 BGE 前 10，gate 就完全没有机会把它排上来。

这个实验要回答：把召回和重排的范围从 10 篇扩到 50 篇，能补回多少，以及要付出多少计算代价。

## 二、实验设置

- 唯一的变量是每跳的候选数 **k**：BGE（[bge-base-en-v1.5](#)）从共享语料库召回前 k 篇，gate v3 对这 k 篇 全部打分，按  $emb\_score - \lambda \times gate\_score$  重排，保留第 1 名作为这一跳的证据（beam 宽度 1）。召回数和 重排数始终相同，对比 k=10 和 k=50 两组。
- 其余配置两组完全相同，也跟 distractor setting 下的 D 组一致：gate v3（rawprefix， $\lambda=0.60$ ， $\lambda$  是在 k=10 下调出来的，这次没有重新调）、BART decomposer、comparison\_hint final reader、Llama-3.1-8B-Instruct。
- 评测口径跟 **D 组**一致：recall@1 / recall@3 按位置对齐，在重排后的完整候选池上计算；chain@1 为整条 证据链全部命中；EM / F1 为 HotpotQA 官方口径。三个数据集都是 dev 全量。

## 三、结果

| 数据集             | 候选数          | recall@1         | recall@3         | chain@1          | EM               | F1               | 耗时   |
|-----------------|--------------|------------------|------------------|------------------|------------------|------------------|------|
| MuSiQue         | top10        | 0.5357           | 0.6329           | 0.2991           | 0.2987           | 0.3858           | 0.6h |
|                 | <b>top50</b> | 0.5438<br>(+0.8) | 0.6616<br>(+2.9) | 0.3136<br>(+1.5) | 0.3136<br>(+1.5) | 0.4022<br>(+1.6) | 2.6h |
| 2WikiMultihopQA | top10        | 0.7881           | 0.8487           | 0.5879           | 0.5130           | 0.5765           | 3.6h |
|                 | <b>top50</b> | 0.7905<br>(+0.2) | 0.8561<br>(+0.7) | 0.5939<br>(+0.6) | 0.5193<br>(+0.6) | 0.5842<br>(+0.8) | 8.8h |
| HotpotQA        | top10        | 0.5325           | 0.6142           | 0.3723           | 0.4362           | 0.5515           | 1.4h |
|                 | <b>top50</b> | 0.5523<br>(+2.0) | 0.6517<br>(+3.8) | 0.4050<br>(+3.3) | 0.4593<br>(+2.3) | 0.5781<br>(+2.7) | 4.3h |

括号内为 top50 相对 top10 的变化，单位 pt。

## 四、分析

**1. 三个数据集、五项指标全部提升，净效果为正。** 候选变多之后，一个潜在风险是：BGE 排名靠后、跟查询不那么相关的段落，靠较低的 gate 分被重排到第一，反而把检索带偏。 $\lambda=0.60$  是在 10 篇候选下调的，这

个风险 事先无法排除。第五节的统计显示这种情况确实存在，一部分原本能排到第一的 gold 被新进入的候选挤了下去， 但被 gate 从第 11-50 名捞上来的 gold 更多，净效果为正， $\lambda$  不用为 top50 重新调也能工作。

**2. 提升主要体现在 recall@3 和 chain@1。** recall@3 提升 0.7-3.8pt，明显大于 recall@1 (0.2-2.0pt)，说明原来有一部分 gold 排在 BGE 第 11-50 名，扩大候选池后被 gate 捞进了前几名，但不一定排到第一。chain@1 的提升 (0.6-3.3pt) 大于单跳 recall@1，因为多跳链条里任意一跳找回 gold 都可能让整条链从错变对，逐跳的 小幅改善会在链条层面累积。

**3. 收益大小因数据集而异：HotpotQA > MuSiQue > 2Wiki。**

- **HotpotQA 提升最大** (EM +2.3、chain@1 +3.3)。原因不是它可补回的 gold 更多——落在 BGE 第 11-50 名的 gold 比例 (6.8%) 反而低于 MuSiQue (9.5%) ——而是 gate 对这部分 gold 的转化率更高 (见第五节)。
- **MuSiQue 次之** (EM +1.5、recall@3 +2.9)，语料库只有 2.1 万篇，但 top10 下 recall@3 同样只有 0.63。
- **2Wiki 提升很小** (EM +0.6、recall@3 +0.7)。第五节的统计给出了原因：2Wiki 的 gold 要么已经在 BGE 前 10 篇里 (85.3%)，要么排在 100 名以外 (12.9%)，落在第 11-50 名的只有 1.3%，扩大候选池几乎没有可以 补回的对象。

**4. 计算代价是 2.4-4.4 倍耗时。** gate 需要对每个候选单独做一次 Llama 前向提取隐藏状态，候选从 10 篇变成 50 篇，这部分计算量约为 5 倍；答案生成等其他环节不变，所以总耗时增加 2.4 倍 (2Wiki) 到 4.4 倍 (MuSiQue)。按"每增加 1 小时耗时换来的 EM 提升"算，HotpotQA (+2.3pt / +2.9h) 和 MuSiQue (+1.5pt / +2.0h) 性价比 尚可，2Wiki (+0.6pt / +5.2h) 很低。

## 五、候选池分析：gold 在 BGE 排序中排第几，gate 又把它排到了哪里

为了解释上面三个数据集收益的差异，对每一跳统计了两件事 (不调用 LLM，只重新编码查询)：

- **gold 在 BGE 排序中的名次**：用这一跳实际发出的查询 (检索指令前缀 + 用前几跳短答案展开后的子问题)，对整个共享语料库计算相似度，看按位置对齐的 gold 排第几。
- **gate 重排后 gold 的位置**：直接读 top50 评测记录的每跳完整候选池 (重排后的顺序)。

统计口径跟 recall@k 完全一致 (同一批跳、同样按位置对齐)，并做了两项自检：由记录的候选池重新计算的 recall@1/@3 跟两组评测报告的数字逐位一致；"BGE 名次  $\leq k$ "跟"gold 出现在记录的 top-k 候选池里"的一致率为 99.99%-100%。

### 5.1 gold 在 BGE 排序中的名次分布

(查询取自 top10 那组评测)

| 数据集             | 前 10  | 11-50       | 51-100 | 100 名以外 |
|-----------------|-------|-------------|--------|---------|
| MuSiQue         | 67.9% | <b>9.5%</b> | 3.5%   | 19.1%   |
| 2WikiMultihopQA | 85.3% | <b>1.3%</b> | 0.5%   | 12.9%   |
| HotpotQA        | 64.2% | <b>6.8%</b> | 2.8%   | 26.3%   |

从 top10 扩到 top50，能新增进入候选池的只有 11-50 这一档。2Wiki 这一档只有 1.3%，gold 的分布是"两极"的：绝大多数在前 10，剩下的几乎都在 100 名以外，中间几乎没有——这就是扩大候选池对 2Wiki 基本无效的原因。

5.2 top50 下，gate 把不同名次的 gold 排到了哪里

(查询取自 top50 那组评测)

| 数据集             | BGE 前 10：占比 → 重排后<br>第 1 / 前 3 | BGE 11-50：占比 → 重排后<br>第 1 / 前 3 | BGE 50 名以<br>外：占比 |
|-----------------|--------------------------------|---------------------------------|-------------------|
| MuSiQue         | 68.1% → 76.7% / 90.9%          | 9.4% → <b>23.1%</b> / 45.9%     | 22.5%             |
| 2WikiMultihopQA | 85.2% → 92.0% / 99.2%          | 1.4% → <b>45.6%</b> / 76.3%     | 13.4%             |
| HotpotQA        | 64.4% → 81.8% / 94.1%          | 6.8% → <b>37.3%</b> / 67.5%     | 28.8%             |

recall@1 的净变化由一增一减两部分组成：

- **增**：原本在候选池外（BGE 11-50 名）、被 gate 重排到第 1 名的 gold，折合占全部跳的 2.2%（MuSiQue）、0.6%（2Wiki）、2.5%（HotpotQA）。
- **减**：候选变多后，一部分原本能排到第 1 的 gold 被新进入的候选挤了下去。同样在 BGE 前 10 的 gold，重排后排第 1 的比例从 top10 到 top50 分别为 78.9% → 76.7%（MuSiQue）、92.4% → 92.0%（2Wiki）、82.9% → 81.8%（HotpotQA）。两组评测后几跳的查询因前面检索结果不同而略有差异，这个对比是近似的。

两者相抵，就是 recall@1 的净提升 +0.8 / +0.2 / +2.0pt。HotpotQA 净提升最大，是因为 gate 对新进入候选池的 gold 转化率更高（37% vs MuSiQue 的 23%），被挤掉的也更少。

5.3 瓶颈在 BGE 前 50 名以外

**13%-29% 的跳，gold 排在 BGE 50 名以外，其中大部分在 100 名以外**（MuSiQue 19.1%、2Wiki 12.9%、HotpotQA 26.3%），重排范围再大也救不回来。继续扩到 top100，也只能让 MuSiQue / 2Wiki / HotpotQA 分别再多 3.5 / 0.5 / 2.8 个百分点的跳的 gold 进入候选池，而 gate 的计算量还要再翻一倍。global 与 distractor 之间剩下的差距，主要不在重排范围，而在检索这一步本身：gold 根本没有被 BGE 召回。

六、跟 distractor setting 的差距

作为参照，同一套配置在 distractor setting（每题只在自带的约 20 篇段落里检索）下的结果：

| 数据集             | distractor EM /<br>F1 | global top10 EM / F1            | global top50 EM / F1            |
|-----------------|-----------------------|---------------------------------|---------------------------------|
| MuSiQue         | 0.4386 / 0.5341       | 0.2987 / 0.3858 (−14.0 / −14.8) | 0.3136 / 0.4022 (−12.5 / −13.2) |
| 2WikiMultihopQA | 0.6023 / 0.6819       | 0.5130 / 0.5765 (−8.9 / −10.5)  | 0.5193 / 0.5842 (−8.3 / −9.8)   |
| HotpotQA        | 0.5519 / 0.6883       | 0.4362 / 0.5515 (−11.6 / −13.7) | 0.4593 / 0.5781 (−9.3 / −11.0)  |

括号内为相对 distractor 的差距，单位 pt。扩大到 top50 把 global 和 distractor 之间的 EM 差距缩小了 0.6-2.3pt，但仍有 8-12pt 的差距。候选池从约 20 篇变成几万篇带来的检索难度，单靠扩大召回范围只能补回一小部分。

## 七、小结

- 在 global setting 下，把召回和重排范围从 top10 扩到 top50，三个数据集全部指标提升：EM +0.6 (2Wiki) 到 +2.3pt (HotpotQA)，chain@1 +0.6 到 +3.3pt，gate 和  $\lambda$  在更大的候选池下依然有效。
- 收益取决于两点：gold 落在 BGE 第 11-50 名的比例 (MuSiQue 9.5%、HotpotQA 6.8%、2Wiki 1.3%)，以及 gate 能把其中多少排到第一 (23% / 37% / 46%)。2Wiki 的 gold 几乎不落在这一档，所以收益很小。
- 代价是 2.4-4.4 倍耗时；扩大候选池只能补回 global 与 distractor 之间差距的一小部分。13%-29% 的跳 gold 排在 BGE 50 名以外、大部分在 100 名以外，剩余 8-12pt 的差距主要来自这一步——要继续缩小，需要改进查询 或检索器本身，而不是继续扩大重排范围。